### UNIVERZITA KOMENSKÉHO V BRATISLAVE FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY



## SÉMANTICKÉ PUBLIKOVANIE SPRAVODAJSKÝCH DÁT O BEZPEČNOSTNÝCH HROZBÁCH

Diplomová práca

### UNIVERZITA KOMENSKÉHO V BRATISLAVE FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY



### SÉMANTICKÉ PUBLIKOVANIE SPRAVODAJSKÝCH DÁT O BEZPEČNOSTNÝCH HROZBÁCH

Diplomová práca

Študijný program: Aplikovaná informatika

Študijný odbor: 2511 Aplikovaná informatika

Školiace pracovisko: Katedra aplikovanej informatiky

Školiteľ: doc. RNDr. Martin Homola, PhD.

Bratislava, 2021

Bc. Matej Rychtárik





### Univerzita Komenského v Bratislave Fakulta matematiky, fyziky a informatiky

#### ZADANIE ZÁVEREČNEJ PRÁCE

Meno a priezvisko študenta:	Bc. Matej Rychtárik
-----------------------------	---------------------

**Študijný program:** aplikovaná informatika (Jednoodborové štúdium,

magisterský II. st., denná forma)

Študijný odbor:informatikaTyp záverečnej práce:diplomováJazyk záverečnej práce:slovenskýSekundárny jazyk:anglický

**Názov:** Sémantické publikovanie spravodajských dát o bezpečnostných hrozbách

Semantic punishing of security threat intelligence data

Anotácia: V súčasnosti zaznamenávame veľké množstvo nových spravodajských dát

o rôznych bezpečnostných hrozbách. Pre popis a publikovanie týchto dát vznikli v minulosti viaceré štandardy. Nový trend v oblasti však ukazuje potrebu sémantickej anotácie týchto dát za účelom zvýšenia ich dosahu

a interoperability.

Cieľ: Cieľom je navrhnúť vhodnú ontológiu pre publikovanie spravodajských dát

o bezpečnostných hrozbách a vytvorenie repozitára za týmto účelom v sieti

prepojených dát.

Literatúra: [1] Allemang, D. and Hendler, J., 2011. Semantic web for the working

ontologist: effective modeling in RDFS and OWL. Elsevier.

[2] Heath, T. and Bizer, C., 2011. Linked data: Evolving the web into a global data space. Synthesis lectures on the semantic web: theory and technology, 1(1),

pp.1-136.

[3] Mavroeidis, V. and Bromander, S., 2017. Cyber threat intelligence model: an evaluation of taxonomies, sharing standards, and ontologies within cyber threat

intelligence. In EISIC 2017 (pp. 91-98). IEEE.

**Vedúci:** doc. RNDr. Martin Homola, PhD.

Rektorát, dekanát: FMFI.Dek - Dekanát

**Dátum zadania:** 02.10.2019

**Dátum schválenia:** 14.10.2019 prof. RNDr. Roman Ďurikovič, PhD.

garant študijného programu

študent	vedúci práce

Čestne prehlasujem, že túto diplomovú vypracoval samostatne len s použitím uvede	
a za pomoci konzultácií u môjho školiteľa.	enej nieratury
Bratislava, 2021	Bc. Matej Rychtárik

# Poďakovanie

Touto cestou by som sa chcel v prvom rade poďakovať môjmu školiteľovi doc. RNDr. Martinovi Homolovi, PhD. za jeho cenné rady a usmernenia, ktoré mi veľmi pomohli pri riešení tejto diplomovej práce.

# Abstrakt

Abstrakt v slovenčine

# Abstract

An abstract in english language

# Obsah

# Kapitola 1

# $\mathbf{\acute{U}vod}$

Nejaky strucny uvod do problematiky

# Časť I

Prehľad problematiky

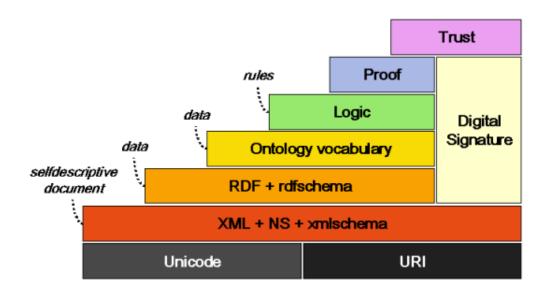
## Kapitola 2

# Sémantický web

Sémantický web? poskytuje spoločný framework, ktorý umožňuje zdieľanie a opätovné použitie údajov v rámci aplikácií. Štandardy podporujú spoločné dátové formáty a protokoly, kde najpodstatnejším je Resource Description Framework (RDF). Prvýkrát pojem Sémantický web zaviedol Tim Berners-Lee a popisoval "dátový web", ktorý môže byť strojovo čitateľný. Zámerom je zlepšiť prístupnosť informácií publikovaných na webe pre strojové spracovanie. Sémantický web má vrstvovú štruktúru ako si môžeme všimnúť na obrázku 2.1. Jednotlivé údaje sú potrebné až vo vyšších vrstvách.

XML vrstva zaručuje, že môžeme spájať Sémantický web s inými normami, založenými napríklad na XML, ktorá je rozšírená a podporovaná a RDF dáta sa v nej dajú dobre prenášať, spracovávať a uchovávať. Toto je už ale pre dnešné časy neštandartné a viac sa využíva výmena dát pomocou JSON formátu.

RDF je metóda popisovania vecí pomocou vzťahu medzi dvoma objektami. Napríklad koncepčne povedané "Jožko má jablko" je zadefinovaním spojenia medzi objektami "Jožko" a "jablko" pomocou



Obr. 2.1: Semantic Web - vrstvy. Zdroj: ?

vzťahu "má". Toto spojenie je známe ako triplet, ktorý je základnou stavebnou jednotkou sémantického webu.

RDF je aj názov slovníka, ktorý obsahuje množinu preddefinovaných termínov. Tieto termíny sú všeobecne používané na popis dát. Napríklad obsahuje najzákladnejšiu vlastnosť pre objekty a to vlastnosť typu objektu – rdf:type.

RDFS je taktiež slovník. V RDF slovníku máme termíny, ktoré nám pomáhajú určovať definície a popisy jednotlivých objektov. V RDFS získavame možnosť popisovať triedy. Pokiaľ si zoberieme triedu "Osoba" a triedu "Žena", vieme pomocou RDFS slovníka zadefinovať vzťah podtriedy vlastnosťou "rdfs:subClassOff". Vďaka slovníkom RDF a RDFS môžeme tvoriť detailné popísanie našich dát.

Ontológia je v našom ponímaní synonymom k slovu slovník. Slovník RDFS môže byť použitý na tvorbu vlastnej ontológie. Sú v nej definované

Vďaka takejto reprezentácii dát je možné písať pravidlá, ktoré má daný

súbor dát spĺnať. Vďaka logickej vrstve vieme napríklad zadefinovať pravidlá ako: Všetky objekty typu "Muž" a "Žena" sú zároveň typom "Osoba" alebo Množina objektov s typom "Muž" je disjunktná s množinou objektov "Žena". Tieto pravidlá slúžia na kontrolu konzistentnosti našich dát.

Text uvedený nižšie popisuje niekoľko technológií, ktoré sú potrebné pre tvorbu sémantického webu.

#### 2.1 Linked Data

Linked Data ? je metóda zverjňovania štrukturovaných dát. Ich hlavným cieľom je poprepájať existujúce databázy (primárne písané v RDF formáte), medzi rôznymi údajmi a umožniť ľuďom zdielať štrukturované dáta na webe pomocou HTML. Časť vízie do budúcna je, aby sa Internet stal globálnou databázou. Princípy Linked Data prvýkrát načrtol Tim Berners-Lee. Popísal 4 pravidlá pre zverejňovanie dát na webe:

- používať URI ako názvy objektov, ktoré sú identifikátormi informácie, jej umiestnenia a ďalších vlastnotí,
- 2. používať HTTP URI, aby si ich ľudia vedeli pozrieť,
- uvádzať informácie o tom, čo názov identifikuje pri vyhľadávaní pomocou otvorených štandardov, ako sú napríklad RDF alebo SPARQL,
- 4. pri publikovaní údajov na webe, zahrnúť odkazy aj na iné URI, aby sa dalo objavovať viac vecí.

Sú známe aj ako Linked Data princípy.

### 2.2 Resource Description Framework (RDF)

RDF? je štandartný model na zakódovanie metadát a ďalších informácií. Je to taktiež formát, ktorý bol navrhnutý a štandardizovaný na reprezentáciu dát pre sémantický web. Zdroje týchto dát sú väčšinou webové zdroje, ktoré môžu byť čokoľvek, napríklad dokumenty, ľudia, fyzické objekty, atď. Taktiež poskytuje spoločný framework na vyjadrenie informácií a možnosť zdieľať ich medzi softvérmi, bez straty ich hodnoty. Dáta sa uchovávajú v Triple Store databázach, ktorých formát je striktne daný. Výhodou je, že dáta môžu byť spracované aj softvérmi, pre ktoré dané dáta neboli vytvorené.

RDF súbor je taký dokument, ktorý ukladá RDF grafy do špecifického formátu serializácie pre RDF, ako sú napríklad N-Triple, TURTLE, RDF/XML a mnohé ďalšie. RDF bol postavený na myšlienke vytvárať údaje vo forme predmet-predikát-objekt, ktorý sa volá triplet. Triplet je základná stavebná jednotka akejkoľvek množiny dát zapísaných v RDF. Tieto údaje sú reprezentované ako orientované grafy. Predmet a objekt predstavujú vrcholy a predikát je orientovaná hrana medzi nimi. Predmet môže byť použítý aj ako objekt v inom triplete. Týmto spôsobom sa triplety prepájajú a vzniká z nich grafová databáza. Predmet je vždy definovaný ako URI a popisuje zdroj informácie. Objekt môže byť taktiež nejaké URI popisujúce zdroj, ale taktiež to môže byť primitívna hodnota, ako napríklad string, integer, date, atď. Predikát popisuje, aký vzťah alebo predmetom a objektom existuje. Predikát reprezentovaný ako URI, ktoré pochádza z ontolológií (kolekcie viacerých URI).

Na uľahčenie ukladania a čitateľnosti dát sa využívajú takzvané prefixy, ktoré sú preddefinovaním základných URI, do ktorých sa dodáva zvyšná hodnota URI pomocou dvojbodky, ako je to uvedené v nasledujúcom

príklade a graficky znázornené v obrázku 2.2.

@prefix rdf: <http://www.w3.org/1999/02/22-rdf-syntax-ns> .

@prefix dbr: <http://dbpedia.org/resource/> .

@prefix dbo: <http://dbpedia.org/ontology/> .

@prefix dbp:<http://dbpedia.org/property/> .

dbr:Bratislava dbo:highestPlace dbr:Devinska\_Kobyla .

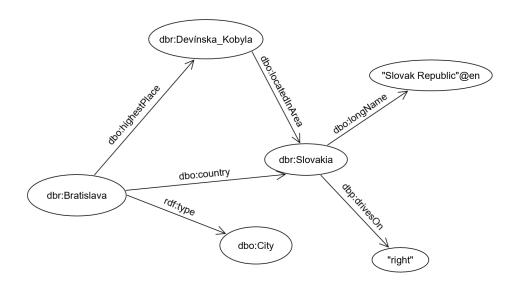
dbr:Bratislava rdf:type dbo:City .

dbr:Bratislava dbo:country dbr:Slovakia .

dbr:Devinska\_Kobyla dbo:locatedInArea dbr:Slovakia .

dbr:Slovakia dbp:drivesOn "right" .

dbr:Slovakia dbo:longName "Slovak Republic"@en .



Obr. 2.2: Príklad grafovej databázy.

### 2.3 SPARQL

SPARQL ? je dopytovací jazyk pre RDF databázy, ktorý umožňuje získavanie a manipuláciu s databázou. Bol vytvorený skupinou DAWG, ktorá je súčasťou W3C a je uznávaný ako kľúčová technológia sémantického webu.

Ak by sme porovnali SPARQL s dopytovacím jazykom pre relačné datábazy, napr. SQL, zistíme, že sú si podobné v kľúčových slovách, ako sú napr. SELECT, WHERE, FROM atď. SPARQL dopyt využíva trojice ako základný prvok, kde predmet, predikát alebo objekt môžu byť premenné. Dopyt sa robí nad dátovou kolekciou RDF, čo je množina dokumentov, patriaca pod určitý koncový bod - 'endpoint'. Je to dopytovací jazyk, ktorý z orientovaného ohodnoteného grafu zisťuje hodnoty jednotlivých vrcholov a hrán, ktoré sú výstupnými parametrami dopytu.

Príklad dopytu nad databázou uvedenou vyššie, spúšťame nad endpointom DBPedia a výsledok je len zlomkom z toho, čo nám skutočne

vráti: Chceme získať všetky údaje o Bratislave.

Okrem operácie SELECT poznáme aj ďalšie typy dopytov. ASK je dopyt, ktorý nám vracia pravdivostnú hodnotu pre daný dopyt. Vieme ním napríklad zistiť či sa v našom grafe nachádza mesto Bratislava. Taktiež poznáme dopyt DESCRIBE, ktorý vracia RDF graf opisujúci jednotlivé vlatnosti výsledných hodnôt dopytu. Ako posledný typ dopytu je CONSTRUCT, ktorý vracia nový RDF graf podľa predlohy vytvorenej v hlave dopytu.

## Kapitola 3

# Ontológie

Výraz ontológia ? pochádza z gréckeho slova kde 'ontos' znamená existencia a 'logos' znamená veda. Ontológia v informatike je uceleným popisom pojmov v určitej oblasti záujmu. Obsahuje určitú klasifikáciu údajov do hierarchicky usporiadaných kategórií a množinu odvodzovacích pravidiel, pomocou ktorých je možné z faktov odvodiť nové skutočnosti. Prostredníctvom ontológií je možné vytvárať spojenia, vykonávať analýzu údajov a sprostredkovať výhody webu obohateného o sémantiku.

Jej cieľmi je zadefinovanie a zdieľanie jednotného zápisu informácií pre danú doménu. Ak napríklad viac stránok využíva na popis pojmov takúto zadefinovanú ontológiu, vedia boti získať a vyhľadávať viac dát o hľadanej informácii.

Taktiež je jej cieľom opätovné použitie ontológie, napríklad ak máme dobre zadefinovanú ontológiu, môžu ontologický inžinieri doplniť do našej ontológie ďalšie vlastnosti a tým by základ ontológie bol rovnaký ale bol by rozšírený o určité dáta, podľa potreby ontologických inžinierov.

### 3.1 Základné pojmy

Ontológia sa skladá zo základných stavebných prvkov *Trieda*, *Entita*, *Atribút*, *Vzťah*.

**Triedy** alebo typy definujú skupiny alebo množiny objektov. Triedy majú hierarchickú štruktúru zloženú z ich podtried. Každá podtrieba spĺňa vlastnosti nadtriedy a môže byť rozšírená o vlastné vlastnosti.

Entity sú individuálne inštancie nejakej nami zadefinovanej triedy. Ak by sme mali entitu Bratislava, a triedy Mesto a Hlavné mesto, kde Mesto je podtriedou Hlavné mesto, tak nám z ontológie vyplýva, že ak je entita Bratislava individuálnou inštanciou triedy Hlavné mesto, tak je aj individuálnou inštanciou triedy Mesto.

Atribúty sú vlastnosti *Tried* a *Entít* a môžu niesť rôzne informácie o danom objekte. *Atribúty* môžu mať rôzne hodnoty, ako reťazec, číslo, dátum alebo pravdivostnú hodnotu. Ak by sme si zobrali predchádzajúcu entitu *Bratislava*, jej číselná vlastnosť môže byť napríklad počet obyvateľov.

Vzťahy sú najpodstatnejšou súčasťou ontológie. Poskytujú prepájanie jednotlivých entít. Je to jednosmerné spojenie, ktoré určuje vzťah, v akom sú dve dané triedy. Tým vznikne triplet trieda:vzťah:trieda. Medzi triplet sa radí aj trojica trieda:atribút:hodnota. Väzby sa zvyknú definovať aj inverzne. Z logického hľadiska sú vzťahy axiómami. Pokiaľ máme triedu Krajina a Hlavné mesto, tak by vzťah mohol vyzerať nasledovne: Krajina:má:Hlavné mesto.

TBox je množina definícií tried a ich vzťahov medzi nimi. V množine je obsiahnutá znalosť taxonómie tried, taktiež v nej môže byť zadefinovaná disjunktnosť jednotlivých tried, vymenovanie konkrétnych entít obsiahnutých v danej triede, reštrickie pre jednotlivé triedy a ich vzťahy

**ABox** je množina znalostí o jednotlivých entitách.

Ontológia má veľa vlastností, ktoré musia byť dodržané. Každý prvok musí byť jasne indetifikovateľný. Taktiež zakazuje zapisovanie duplicitných dát, čo nám zaobstará vlastnosť efektívneho ukladania informácií, kde to môže nie len uľahčiť vyhľadávanie ale aj zredukovať obsah pamäti na disku.

### 3.2 Využitie ontológií

Ontológie sa začali využívať najmä v organizáciách, ktoré sa šoecializovali na umelú inteligenciu. Neskôr sa to rozšírilo aj do bežne používaných aplikácií. Napríklad firma Amazon používa ontológie na kategorizovanie tovaru v ich elektronickom obchode.

Ontológie si našli uplatnenie aj v medicínskej oblasti a to napríklad SNOMED, čo je najväčším viacjazyčným medicínskym slovníkom na svete.

Taktiež sa s ním stretávame každodenne pri vyhľadávaní na stránke Google, kde ako bočný panel sú zobrazené informácie o vyhľadávanom objekte (obrázok nižšie). Tieto dáta je možné zobraziť preto, lebo výsledkom takéhoto panelu je vyhľadávanie informácií na webovej stránke, ktorá obsahuje sémantické dáta.

Na získavanie dát zo sémantických webov a z RDF úložísk sú využívane SPARQL dopyty. Syntax jazyku SPARQL je veľmi podobná klasickému SQL jazyku, kde aj SPARQL umožňuje okrem dopytovania aj vkladanie, editáciu a vymazávanie dát.

### 3.3 Syntax ontológií

Popis moznosti

#### 3.3.1 Web Ontology Language

Jazyk Web Ontology Language alebo OWL slúži na vytváranie a definovanie inštancií webových ontológií. Poskytuje nástroje na popis tried, vlastností a ich samotných inštancií. Oproti klasickým jazykom poskytje možnosť, špecifikovať logické vlastnosti jednotlivých objektov vyskytujúcich sa v ontológií, to znamená, že dokáže popísať aj fakty, ktoré v ontológií nie sú definované priamo, ale sú spojené logickými vlastnosťami. Napríklad, ak máme osoby Janka, Martin a Jozef, kde Janka je rodičom Martina a Jozef je rodičom Janky, pomocou OWL vieme definovať že Jozef je starým rodičom Martina, pričom nepotrebujeme vlastnosť popisujúcu tento vzťah priamo.

#### 3.3.2 Druhy OWL

Jazyk OWL poskztuje 3 podjazyky, ktoré sú použitľné v rôznych situáciách.

OWL Lite poskytuje definície na tvorbu hierarchického rozdelenia objektov a jednoduché obmedzenia. Jednoduchými obmedzeniami sa myslí napríklad obmedzenie kardinálnej vlastnosti a to iba na hodnoty 0 a 1.

OWL DL

OWL Full

Každý, kto sa rozhodne vyvýjať ontológiu použitím OWL, by mal zvážiť, ktorý typ je najlepší pre danú ontológiu. Najmä treba zvážiť aké obmedzenia je potrebné pre ich ontológiu definovať.

### 3.3.3 Syntax

Normovaná syntax OWL jazyka je RDF/XML. OWL je jazyk, ktorý rozširuje jazyk RDF.

Základná časť každej ontológie by mala obsahovať menný priestor, kde si definujeme množinu slovníkov používaných v našej ontológií.

```
<rdf: RDF

xmlns = "http://www.semanticweb.org/example"

xmlns:rdf = "http://www.w3.org/1999/02/22-rdf-syntax-ns#"

xmlns:rdfs= "http://www.w3.org/2000/01/rdf-schema#"

xmlns:owl = "http://www.w3.org/2002/07/owl#"
>
```

Prvá deklarácia definuje menný priestor našej ontológie. Zvyšné deklarácie definujú ďalšie slovníky použité v ontológii.

Po vytvorení menného priestoru si potrebujeme všeobecne definovať našu vlastnú ontológiu. V tejto definícii sa nachádzajú informácie ako komentár k ontológii a názov ontológii a taktiež vieme definovať rôzne ontológie, ktoré budú súčasťou ontológie.

```
<owl:Ontology rdf:about = "">
    <rdfs:comment>Priklad ontológie OWL o osobách</rdfs:comment>
    <owl:priorVersion
      rdf:resource = "http://www.semanticweb.org/example/1.15" />
      <owl:import rdf:resource = "http://www.semanticweb.org/food" />
      <rdfs:label>Ontológia osôb</rdfs:label>
<owl:Ontology>
```

Vlastnosť owl:import pridá externú ontológiu do našej pomocou definovaného zdroja cez vlastnosť rdf:resource. Pomocou owl:priorVersion vieme definovať verziovanie ontológií.

Ďalej si potrebujeme vedieť definovať triedy v ontológii. Na to nám slúži element owl:Class, v ktorom vieme zadeklarovať definíciu danej triedy

pomocou vlastnosti rdf:ID.

```
<owl:Class rdf:ID = "Muž" />
<owl:Class rdf:ID = "Žena" />
```

Hierachické usporiadanie tried vieme ďalej definovať pomocou vlastnosti rdfs:subClassOf, ktorej definujeme jej nadtriedu pomocou vlastnosti rdf:resource. Týchto nadtried vieme definovať viac.

```
<owl:Class rdf:ID = "Manžel">
  <rdfs:subClassOf rdf:resource = "Muž">
    ...
</owl:Class>
```

Pre triedu vieme definovať aj slovný popis a názov. Tento názov vieme definovať v rôznych jazykoch použitím vlastnosti xml:lang. Vlastnosť rdfs:label definuje pre bežného človeka ľahko čitateľný názov triedy. Najčastejšie sa využíva táto vlastnosť pri prezentačných nástrojoch ontológií.

```
<owl:Class rdf:ID = "Manžel">
  <rdfs:subClassOf rdf:resource = "Muž">
  <rdfs:label xml:lang="en">Husband</rdfs:label>
  <rdfs:label xml:lang="sk">Manžel</rdfs:label>
  ...
</owl:Class>
```

### 3.4 Deskripčná logika

zakladna syntax ktoru budeme pouzivat neskor na popisanie nasej ontologie

# Kapitola 4

# Existujúce ontologické riešenia

Množstvo kyber útokov v dnešnej dobe narastá závratnou rýchlosťou, čo značí že dnešné spôsoby a metódy ochrany nie sú dostatočné a preto je potrebné sa zamyslieť nad novými spôsobmi ochrany. Jeden z prístupov by mohol byť založený práve na ontológiách. Ontológie a systémy postavené nad nimi majú výhodu sémantiky, ktorá je schopná rozlišovať situácie kedy je počítačový systém normálny alebo škodlivý.

Problém s ktorým sa ale potýkame je ten, že neexistuje jednotný formát zápisu údajov. Väčšina nástrojov ktoré v dnešnej dobe existujú, majú vlastné štandardy. Keďže tieto štandardy sú prevažne rozdielne, nedá sa ich prepájať a využívať efektívne. Tneto problém by mohol byť taktiež vyriešený vďaka ontologickému riešeniu. Tým pádom by sme vedeli mať také dáta, ktoré dokážu stroje nielen prečítať, ale zároveň aj pochopiť.

Ontologiký prístup taktiež poskytuje jednoduchšiu rozšíriteľnosť už existujúcej ontológie a tým sa dá vytvárať presnejší popis záznamov.

Vďaka URI reprezentácií jednotlivých entít, ktoré sú používané ako identifikátory jednotlivých objektov, nemôže nastať problém nepochopenia dát ako k tomu môže doochádzať v ľudskej reči. Napríklad ak by sme

povedali slovo *koruna*, nikto nevie, či máme na mysli korunu stromov alebo kráľovskú korunu. Avšak vďaka atribútom vieme toto slovo lepšie pochoiť, keďže nám ho atribúty bližšie definujú.

V súčastosti existuje veľa rôznych štandardov a ontologických riešení pre doménu kzber bezpečnosti, avšak veľa z nich už ani nie je vyvýjaných. Organizácie, ktoré vyvýjali tieto ontológie, buď stratili o ďalší vývoj záujem, alebo už len nezverejňujú svoje pokroky v danej doméne, teda prešli na closed-source systém.

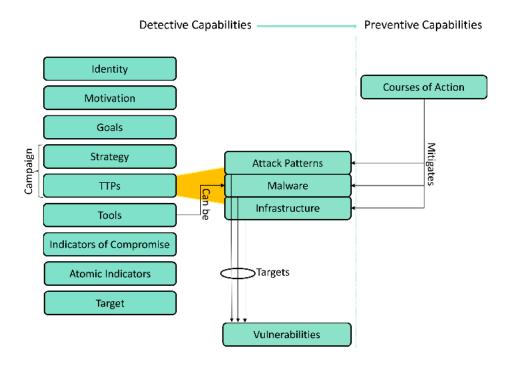
V nasledujúcich kapitolách si povieme niečo o zaužívaných štandardoch, základnom modeli, z ktorého vychádzame a podľa, ktorého posudzujeme, či je daná ontológia dobrá. Taktiež rozoberieme existujúce riešenia v doméne kyber bezpečnosti.

#### 4.1 CTI model

Cyber Threat Intelligance model (?) (CTI model) má za cieľ objasňovať rôzne typy informácií, ktoré potrebujú organizácie zhromažďovať o kybernetických hrozbách. Cieľom modelu je jednotne definovať a podrobne popísať okruhy v danej doméne. Výhodou takéhoto modelu je zlepšenie schopností pri prevencii, detekcii a reakcii na bezpečnostné hrozby.

Tento model bol vyvinutý so zámerom, aby slúžil ako predloha pre ontologické riešenia, nakoľko autori zahrnuli fakt, že ontologické riešenia sú najlepšie pri publikovaní a zdieľaní dát a sú strojovo čitateľné vďaka typu reprezentácie.

Model zahŕňa informácie o autorovi útoku, motivácie a ciele útoku, stratégiu akou je útok vedený, aké technológie a postupy používa, ktorým základným vzorcom útoku sa riadi, aké slabiny jednotlivé útoky využili, aké



Obr. 4.1: CTI model. Zdroj: (?)

atomické indikátory dokážu predpovedať útok a akú cieľovú skupinu útok postihuje.

V nasledujúcich častiach popíšeme niektoré okruhy z obr. 4.1, ktorý znázorňuje jednotlivé prvky modelu.

#### 4.1.1 Identita

Identita môže byť definovaná rôznymi typmi identifikátorov. Ak sa pozná presná totožnosť osoby alebo organizácie, ktorá útok iniciuje, identifikátorom je názov osoby alebo spoločnosti.

Pokiaľ takýto identifikátor nevieme určiť, prideľujeme im anonymnú identitu, ktorú následne vieme spájať vyhodnotením útoku. Pokiaľ zoberieme do úvahy všetky ostatné časti CTI modelu a vyhodnotíme

zhodujúce sa časti, vieme povedať, za ktoré útoky zodpovedá rovnaká osoba alebo organizácia.

#### 4.1.2 Kampaň

Kampaň popisuje samtotný útok z dvoch pohľadov. Netechnický, ktorý je reprezentovaný stratégiou a technický, ktorý definuje taktiky, techniky a procedúry využívané v útoku.

#### Stratégia

Stratégia predstavuje netechnický popis útoku na hornej úrovni. Pokiaľ si zoberieme nejakého útočníka, tak tento útočník zvyčajne dosahuje ciele útoku viacerými spôsobmi a stratégia definuje, čo a ako je potrebné pozorovať.

#### 4.1.3 Zraniteľnosť

Zraniteľnosti definujú slabiny systému. Tieto slabiny môžu byť definované rôznymi stavmi zariadenia ako napríklad, ktoré systémy bežia, ale môžu predstavovať aj nastavenia rôznych aplikácií, napríklad rôzne prístupové nastavenia a povolenia pre webové prehliadače. Taktiež môžu popisovať rôzne funkcie, ktoré umožňujú vykonávať jednotlivé systémy, ako napríklad spúšťanie rôznych príkazov ktoré ovplyvňujú a menia systémové nastavenia zariadenie.

#### TTP

Taktiky, techniky a procedúry (TTP) sa zamieravajú na dáta čitateľné strojmi. Popisujú spôsoby útoku z hľadiska toho čo chcú dosiahnuť a ako to robia.

Vzorec útoku je jedným z hľadisiek TTP. Definuje akým spôsobom je útok použitý. Napríklad sa tu nachádzajú rôzne úpravy názvov súborov, rôzne prenastavenie časovania a stavov zariadenia, atď.

Malware je taktiež hľadisko z TTP. Definuje typ softvéru, ktorý sa vkladá do systému s úmyslom poškodiť cieľ útoku z hľadiska dôvernosti, integrity alebo dostupnosti. Medzi typické malware patrí vírus, trójsky kôň, červ, metódy tajných vstupov, spyware atď.

Každý okruh z TTP využíva niektoré zraniteľnosti systémov.

#### 4.1.4 Indikátor

Indikátory predstavujú množinu rôznych vlastností zariadenia, kedy je zariadenie náchylné na útok. Tieto indikátory popisujú rôzne nastavenia zariadenia, jeho technické parametre alebo nainštalovaný softvér a vďaka nemu sú schopné definovať rôzne útoky.

Atomické indikátory sú najpremenlivejšie ukazovatele, nakoľko sa po čase menia. Napríklad ak niektoré útoky prebiehajú z určitej IP adresy, tak táto adresa sa môže časom zmeniť. Tieto typy dát môžu pomáhať pri identifikovaní útočníka iba v určitom čase.

#### 4.1.5 Nástroj

Nástroje sú pomôcky, ktoré útočníci inštalujú v zariadení obete. Väčšinou zahŕňa špecializovaný softvér priamo určený na spôsobenie škôd, ako napríklad vzdialené vykonávanie procesov alebo sieťové skenovanie. Taktiež môže byť použitý pre zabránenie detekcie útoku inými systémami.

#### 4.1.6 Zámer

Zámer pomenováva koncový stav objektu útoku. Zámer nemusí byť vopred daný alebo zrejmý. Jednotlivé útoky môžu prebiehať aj s tým, že až počas útoku je zámer známy. Zámerom môže byť napríklad ukradnutie duševného vlastníctva, poškodenie systému, získanie kompromitujúcich dát a podobne.

#### 4.1.7 Ciel'

Cieľom je myslená entita, na ktorú je útok namierený. Takouto entitou môže byť napríklad organizácia, štát alebo konkrétna osoba.

### 4.2 Unified Cybersecurity Ontology

Unified Cybersecurity Ontology (?) alebo skrátene UCO je rozšírením pôvodného projektu Intrusion Detection System (IDS), ktorého tvorcom je rovnaká skupina. Spája viaceré bežne dostupné bezpečnostné štandardy používané v kybernetickej bezpečnosti. Prevažne pokrýva STIX, ktorý je najväčším a najkomplexnejším štandardom, pokrývajúcim najväčšiu časť kybernetickej bezpečnostnej domény ale taktiež pokrýva iné relevatné štandardy ako CVE4, CCE5, CVSS6, CAPEC7, CYBOX8, KillChain9 a STUCCO10.

Aj keď je STIX najkomplexnejším štandardom a zjednocuje všetky informácie o kybernetických hrozbách, má tieto dáta uložené v XML súboroch, takže nepodporuje výhody inferencie v ontológiách, čo UCO poskytuje.

Okrem týchto štandardov obsahuje aj mapovanie na všeobecné databázy ako sú Google Knowledge Graph, DBPedia a Yago. Vďaka týmto

mapovaniam je možné mať prístup k verejným databázam z rôznych domén záujmu.

Základnými triedami, využívanými v UCO sú:

- Means Čo je zamýšľané daným útokom.
- Consequences Dôsledky útoku.
- Attack Typ útoku.
- Attacker Kto je iniciátorom daného útoku.
- Attack-Pattern Vzorec útoku, podľa ktorého je útok riadený.
- Exploit K čomu útok slúži.
- Exploit Target K čomu slúži cieľ alebo výsledok útoku.
- Indicators Indikátor útoku.

Každá z týchto tried je mapovaná na už reálne existujúcu triedu v niektorom z vyššie uvedených štandardov, prevažne na STIX schému.

Ontológia UCO umožňuje analytikom zachytávať špecifické vedomosti o kybernetickej bezpečnosti pomocov termínov a tried z ontológie a taktiež umožňuje písať pravidlá, ktoré sa môžu použiť na odvodenie nových poznatkov.

Vývojári extrahovali dáta z National Vulnerability Database (NVD), ktorá je uložená v XML súboroch. Potom boli namapované na triple store DBPedia a dáta boli uložené na FUSEKI server, ktorý podporuje dopytovanie z rôznych zdrojov rovnako ako ich odvodzovanie.

### 4.3 Integrated Cyber Analysis System

Integrated Cyber Analysis System(?) alebo ICAS je ontológia vytvorená pre TAPIO (Targeted Attack Premonition using Integrated Operational data) nástroj, ktorý je schopný extrahovať dáta z počítačov v jednej sieti do jedného sémantického grafu a tým zjednoduší a urýchli prácu bezpečnostným tímom pri vyhľadávaní ohrození systému, čím by sa zvýšila prehľadnosť dát a tiež znížil dopad útoku.

Samotná ontológia ICAS je veľmi komplexnou, nakoľko obsahuje približne 30 podontológií, kde každá sa špecializuje na inú oblasť v doméne informačnej bezpečnosti.

Nástroj TAPIO spolu s ontológiou ICAS bol vyvýjaný organizáciou DAPRA, ale dátum poslednej úpravy bol v roku 2017, čiže podobne ako UCO sa jedná o projekt ktorý už nie je aktuálny.

#### 4.4 STUCCO

STUCCO (?), ktorej autorom je Iannacone at al. je ontológiou, ktorá je určená na prácu so znalostnými grafovými databázami. Jej základ tvoria scenáre použitia ľudskými používateľmi alebo automatizovanými strojmi. Obsahuje dáta z 13 rôznych štruktúr, ktoré majú rôzne formáty a ktoré sú uložené v rôznych typoch databáz.

STUCCO obsahuje dáta z nasledovných kategórií do ktorých je rozdelená bezpečnostná doména.

- Identita predstavuje totožnosť a vlastnosti útočníka.
- Taktika technika a procedúry (TPP) Popisuje čo daný útok robí a ako to robí.

- Nástroje Aké nástroje sú potrebné pre úspešné vykonaie útoku.
- Atomické indikátory Sem môžu spadať súbory, IP adresy, doménové mená atď. Nanešťastie tieto dáta majú krátku životnosť nakoľko sa stále menia.

# Časť II

Vlastný prínos

## Kapitola 5

# Výskum a Analýza UCO

V tejto časti podrobne analyzujeme a vyhodnocujeme ontológiu(?), ktorú sme si vybrali pre ďalší vývoj a budeme vyhodnocovať UCO ontológiu vzhľadom na CTI model. Pre túto prácu sú pre nás najpodstatnejšie časti Identita, Útok, Kampaň (Stratégia a TTP), Slabina, Indikátor a Nástroj. Na tieto oblasti sa zameriame v nasledujúcich kapitolách, vyhodnotíme, či sú v ontológii popísané dostatočne, či sú prepájané s už existujúcimi ontológiami a či sú ich vlastnosti a hierarchia dostatočné.

### 5.1 Model

Základnou triedou tejto ontológie je *UCO Thing*, ktorá je nadrtiedou každej triedy v ontológii.

Pokiaľ UCO ontológia využíva už existujúcu triedu z inej ontológie, zadefinuje si ju aj pre svoju doménu a pomocou jayzka OWL jej zadefinuje ekvivalentnú triedu, čím zabezpčí opätovné použitie dát pre iný zdroj. Napríklad trieda *Indicator* je vďaka tomuto vzťahu prepojená s ontológiou CAPEC.

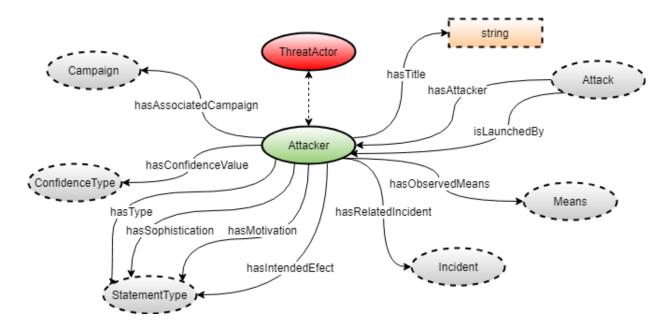
Identita je v ontológii UCO reprezentovaná triedou Attacker, ďalej útočník, ktorý je namapovaný na existujúcu triedu ThreatActor zo STIX-u. Každý útočník má nejaké meno (hasTitle) a je priradený k existujúcim incidentom reprezentovaných triedou Incident priradených vlastnoťou hasRelatedIncident. Má aj určitú mieru doveryhodnosti (hasConfidenceType). Každý útočník má priradené nejaké zavedené postupy a stratégie pri útoku, ktoré sú inštanciou triedy Campaign priradené vlastnosťou hasAssociatedCampaign.

Identita – Attacker			
Vlastnosť	Doména	Rozsah	
${\it has} Associated Campaign$	Attacker	Campaign	
hasConfidenceValue	Attacker	ConfidenceType	
${ m has Intended Effect}$	Attacker	StatementType	
hasMotivation	Attacker	StatementType	
${ m hasObservedMeans}$	Attacker	Means	
${ m has}{ m Related}{ m Incidents}$	Attacker	Incident	
hasSophistication	Attacker	StatementType	
hasType	Attacker	StatementType	
hasTitle	Attacker	xsd:string	

Tabuľka 5.1: Tabuľka vlastností popisujúcej časť **Identita** z CTI modelu.

**Útok** máme reprezentovaný triedou Attack, ktorá má viaceré pravidlá na splnenie. Musí mať minimálne jeden význam (Means) a minimálne jeden následok (Consequence) útoku. Samotný význam je ekvivaletný s triedou TTP, ktorá popisuje samotný útok pomocou informácií o vzoroch útoku, využívaní slabín systémov alebo známych malwaroch. Nakoľko vďaka jazyku OWL vieme definovať napríklad inverzné vlastnosti je žiadúce aby sa táto vlastnosť využívala. Pre vlastnoť hasAttacker to žiaľ nie je zadefinované a určite by to bolo vhodné zadefinovať.

Kampaň je zahrnutá v triede Campaign, ktorá môže existovať iba v

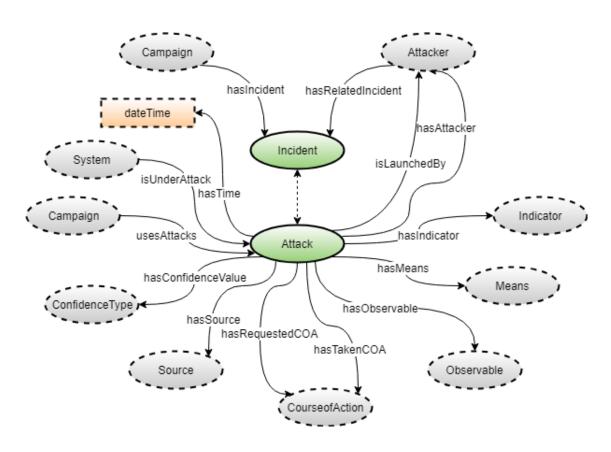


Obr. 5.1: UCO ontológia – časť Identita

Útok – Attack				
Vlastnosť	Doména	Rozsah		
hasAttacker	Attack	Attacker		
hasConfidenceValue	Attack	ConfidenceType		
hasIndicator	Attack	Indicator		
hasMeans	Attack	Means		
hasObservable	Attack	Observable		
hasRequestedCOA	Attack	CourseofAction		
hasSource	Attack	Source		
hasTakenCOA	Attack	CourseofAction		
isLaunchedBy	Attack	Attacker		

Tabuľka 5.2: Tabuľka vlastností popisujúcej časť **Útok** z CTI modelu.

prípade, že už bola použitá v nejakom útoku. Každá kampaň môže taktiež mať nejakú ďalšiu kampaň, ktoré medzi sebou súvisia, kde táto vlastnosť je obojsmerná. Taktiež má vlastnosť hasCampaign, ktorej doménou je trieda *Indicator*. Táto trieda pochádza z ontológie CAPEC, ktorá obsahuje známe vzory útokov.



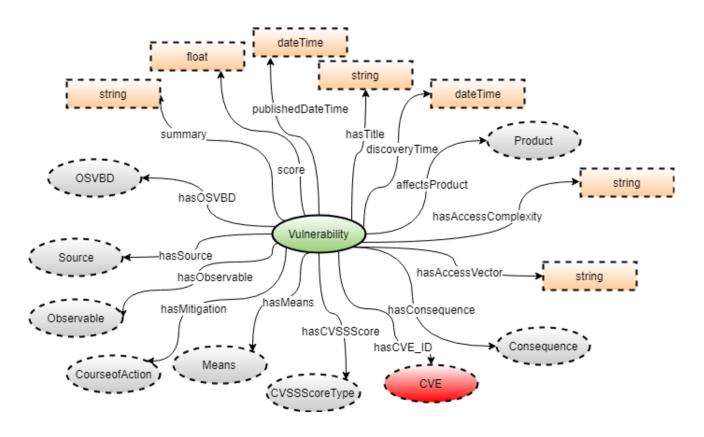
Obr. 5.2: UCO ontológia – časť Útok

Kampaň – Campaign			
Vlastnosť	Doména	Rozsah	
hasAssociatedCampaign	Campaign	Campaign	
hasCampaign	Indicator	Campaign	
hasIndicator	Campaign	Indicator	
hasIncident	Campaign	Incident	
hasMenas	Campaign	Means	
hasStatus	Campaign		
isLaunchedBy	Campaign	Attacker	
usesAttacks	Campaign	Attack	

Tabuľka 5.3: Tabuľka vlastností popisujúcej časť **Kampaň** z CTI modelu.

Slabiny sú zahrnuté v triede Vulnerability, ktorá nie je namapovaná na žiadnnu existujúcu ontológiu, avšak dáta už existujú v rámci databázy CVE, ktorá predstavuje dáta o softvérových a hardvérvých chybách. Tieto slabiny sú naviazané na objekty typu Product vlastnosťou affectsProduct, ktoré môžu byť buď hardvérové alebo softvérové a každá slabina ovplyvňuje produkt. niektorý Taktiež jе nej zaznamený čas objavenia V (discoveryTime), spôsob narušenia alebo preniknutia do systému (hasAccessVector), zložitosť preniknutia do systému (hasAccessComplexity), rôzne typy dopadov alebo skóre úspešnosti (score). Môže niesť aj informáciu o zdroji slabiny. Taktiež definuje objekty, ktoré je potrebné pozorovať, ktoré sú typu Observable. Táto trieda zatiaľ nie je namapovaná na žiadnu existujúcu, ale vieme že existuje ontológia CyBox, ktorá tieto dáta uchováva.

Taktiež existuje trieda *CWE*, ktorá je prepojená s triedou *Weakness* z už existujúcej CWE databázy. Taktiež ako trieda *Vulnerability*, popisuje slabiny z CTI modelu. Trieda *CWE* popisuje známe typy slabostí hardvérov a softvérov. Obsahuje informáciu o čase zistenia (timeOfIntroduction) a stručný popis (description). Zvyšné vlastnosti nemajú definované rozsahy,



Obr. 5.3: UCO ontológia – časť Slabiny

Slabina – Vulnerability			
Vlastnosť	Doména	Rozsah	
affectsProduct	Vulnerability	Product	
discoveryTime	Vulnerability	xsd:dateTime	
exploits Vulnerability	Means	Vulnerability	
hasAccessComplexity	Vulnerability	xsd:string	
hasAccessVector	Vulnerability	xsd:string	
hasConsequences	Vulnerability	Consequence	
hasCVE_ID	Vulnerability	CVE	
has Means	Vulnerability	Means	
hasObservable	Vulnerability	Observable	
${ m published Date Time}$	Vulnerability	xsd:dateTime	
score	Vulnerability	xsd:float	

Tabuľka 5.4: Tabuľka vlastností popisujúcej časť **Slabina** z CTI modelu.

čo je výrazným nedostatkom a je potrebné tieto vlastnosti dodefinovať.

Slabina – CWE			
Vlastnosť	Doména	Rozsah	
timeOfIntroduction	CWE	xsd:dateTime	
$\operatorname{discoveryTime}$	CWE	xsd:dateTime	
${\it commonConsequences}$	CWE	Consequences	

Tabuľka 5.5: Tabuľka vlastností popisujúcej časť **Slabina** z CTI modelu.

Indikátory sú reprezentované triedou Indicator. Táto trieda je namapovaná na už existujúcu triedu z ontológie CAPEC. Indikátory spadajú pod kampane (hasCampaign) a majú určitý dopad (hasImpact). Každý indikátor má aj význam (hasMeans) a objekty na pozorovanie z triedy Observable (hasObservable). Každý indikátor môže mať nejaký iný indikátor, ktorý s ním súvisí (hasRelatedIndicator). Obsahuje aj navrhovaný postup reprezentovaný triedou CourseOfAction (hasSuggestedCOA).

Nástroje TODO – chcem sa pobavit s panom baloghon co by radil medzi ne z uco ontologie, nakolko sa nevidim tolko do tejto domeny aby som vedel povedat ktora do toho spada.

Indikátory – Indicator			
Vlastnosť	Doména	Rozsah	
hasCampaign	Indicator	Campaign	
hasConfidenceValue	Indicator	ConfidenceType	
hasImpact	Indicator	StatementType	
hasIndicator	CWE	Indicator	
hasKillChainPhase	Indicator	KillChainPhase	
hasMeans	Indicator	Means	

Tabuľka 5.6: Tabuľka vlastností popisujúcej časť  ${\bf Indik\'ator}$ z CTI modelu.

## Návrh ontológií

### 6.1 CVE

Common Vulnerabilities and Exposures(CVE) je databáza všetkých chýb zabezpečenia v oblasti kybernetickej bezpečnosti. Jej úlohou je identifikovať, definovať a katagolizovať tieto chyby, ďalej zraniteľnosti. Každá zraniteľnosť má vlastný záznam, ktorý prechádza fázami v databáze. Zraniteľnosť je najprv objavená, potom pridelená a nakoniec zverejnená. Zverejňovať tieto zraniteľnosti môžu iba tí, ktorí majú partnerstvo s programom CVE. Tieto záznamy sú následne používané pri komunikácii a riešení rôznych bezpečnostných hrozieb, aby sa zabezpečilo rovnaké chápanie problému, ktoré bolo konzistentne definované v CVE.

Tieto záznamy majú svoje identifikátory, ktoré sa skladajú z prefixu CVE, následne obsahujú rok objavenia a nakoniec unikátny identifikátor v rámci tejto trojkombinácie. Napríklad identifikátor CVE-2020-0035 predstavuje nejakú zraniteľnosť z roku 2020 v databáze CVE.

Každý jeden záznam má taktiež popis, ktorý musí obsahovať dostatok informácií o tom, na ktoré systémy má daná zranitenosť vplyv, pokiaľ sa

vzťahuje aj na konkrétnu verziu, tak aj táto verzia by mla byť uvedená. Musí obsahovať aj infomácie o type zraniteľnosti, jej príčinu a dopad. Daný popis musí byť napísaný v angličtine.

Záznamy majú aj zoznam referencií, ktoré sú používané ako externé zdroje k zraniteľnosti. Sú to externé odkazy s infomáciou o zdrojovom systéme. Tieto odkazy musia používať iba protokoly http, ftp, https, alebo ftps.

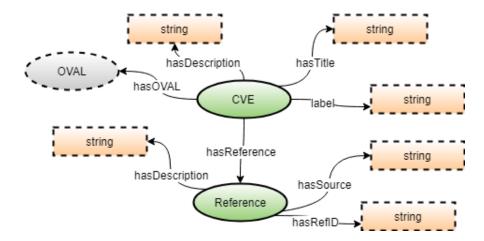
#### 6.1.1 Ontológia

Na základe týchto informácií sme vytvorili ontológiu, ktorá obsahuje základné inforácie zraniteľnosti, podľa požiadaviek štandardu. Ako definíciu zraniteľnosti, používame jej URI, ktorá poskytuje prepoužitie a odkazovanie sa na ňu. Táto zraniteľnosť má taktiež svoj názov, ktorý reprezentujeme ako CVE identifikátor. Každá zraniteľnosť má svoj popis a zoznam referencií. Ako rozšírenie sme použili vlastnosť hasRefId, ktorá definuje unikátny identifikátor, v referencovanom systéme. Tento parameter nie je povinný.

#### 6.2 OVAL

Open Vulnerability and Assessment Language(OVAL) je štandard, ktorý umožňuje popísanie zraniteľností jednotlivých produktov (softvérov). Tieto informácie sú písané vo formáte XML. Obsahuje tri hlavné kroky posudzovania.

Prvým krokom sú základné informácie o systémoch, ako napríklad o aký operačný systém sa jedná, ktoré jeho verzie ohrozuje a aké konkrétne produkty sú ohrozené, pokiaľ je splnená konfigurácia rôznych systémov.



Obr. 6.1: CVE ontológia

Taktiež obsahuje rôzne odkazy na ďaľšie informácie o jednotlivých zraniteľnostiach.

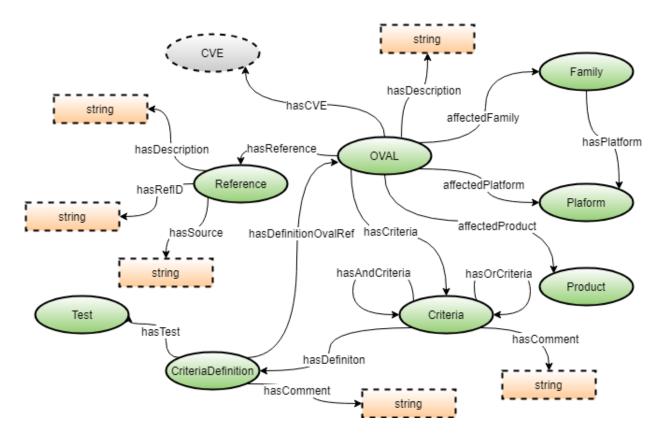
Druhé posudzovanie analyzuje systém podľa špecifikovaného nastavenia a zisťuje či je daný systém ohrozený alebo nie.

Posledný krok tvorí správu o výsledku tejto analýzy. Na výstupe je informácia o aktuálnom konfiguračnom nastavení systému.

### 6.2.1 Ontológia

Pre našu ontológiu nie je potrebné reprezentovať všetky znalosti o OVAL-e. Vybrali sme si konkrétne časti, ktoré je potrebné publikovať v našich spravodajských dátach.

V ontológii reprezentujeme všeobecné informácie popisujúce a definujúce OVAL záznamy, ich vzťahy s jednotlivými operačnými systémami, ich verziami a produktami. Zahŕňame aj informácie o externých zdrojoch pre záznamy. Taktiež predpripravíme ontológiu na reprezentovanie kritérií, ktoré predstavujú logické testy. Tieto testy majú v sebe aj výrokovú logiku reprezentovanú pomocou logických operátorov AND a OR, kde je možné



Obr. 6.2: OVAL ontológia

definovať viacúrovňové logické výrazy.

Každý OVAL objekt je reprezentovaný pomocou URN  $oval:org.cisecurity: \{def\}: 127$  kde  $\{def\}$  musí byť z nasledujúcich možností:

- def jedná sa o záznam definujúci zraniteľnosť
- tst záznam, ktorý definuje test

Samotný záznam sa skladá z:

- has Title názov záznamu
- hasDescription popis záznamu
- affectedFamily operačný systém, ktorý ovplyvňuje

- affectedPlatform akú platformu operačného systému ovplyvňuje
- affectedProduct ktorý produkt ovplyvňuje
- hasReference odkaz na externý zdroj informácií súvisiaci so záznamom
- hasCriteria zoznam logických testov potrebených na zistenie či daný záznam ovplyvňuje systém

Kritériá popisujúce test majú nasledujúce vlastnosti:

- hasAndCriteria logické pravidlo spojené s rodičom AND operátorom
- hasOrCriteria logické pravidlo spojené s rodičom OR operátorom
- hasDefinition definícia kritéria
- hasComment popis kritéria alebo definície kritéria
- hasTest definícia vykonania a kontroly výstupu z testu

## Implementácia a testovanie

#### 7.1 Dáta

Dáta, ktoré sme spracovávali pochádzajú z verejne dostupného zdroja štandardov OVAL a CVE. Tieto dáta mali pôvodne štruktúru XML, ktorá ale nebola písaná OWL syntaxov. Tieto dáta sme spracovali pomocou programovacieho jazyka Python. Jednotlivé triedy v nami navrhnutých ontológiách sme si implementovali a následne sme spracovali dané dátové súbory pomocou knižnice xml. Po spasovaní dát sme tieto dáta definovali pomocou tripletov a následne ich zapísali pomocou knižnice rdflib do súboru vo formáte turtle.

Tento formát sme vybrali najmä kôli menšiemu objemu dát, nakoľko bolo potrebných viac optimalizácií pre generovanie. Ale aj po tejto optimalizácii sme nevedeli spracovať dané záznamy, preto sme sa rozhodli ich rozdeliť. CVE dáta sme spracovali tak, že sme ich rozdelili podľa rokov vytvorenia. OVAL dáta sme rozdelili podľa operaného systému, ktorého sa týkajú. Po zapísaní časti dát, sme túto časť premazali.

### 7.2 Web

V spolupráci so študentami môjho konzultanta, sme vytvorili webovú stránku, založenú na našej ontológii a našich vygenerovaných dátach. Táto stránka poskytuje zobrazenie CVE a OVAL dát, kde je možné tieto dáta prezerať a vyhľadávať. Pomocou SPARQL dopytov sa vyhľadávajú jednotlivé dáta a ich konkrétne informácie.

## Testovanie

### 8.1 Ontológia

postup a popis vyhodnocovania konzistentnosti TBox-u

### 8.2 Dáta

postup a popis vyhodnocovania konzistentnosti ABox-u

## Záver

### 9.1 Zhrnutie

Co sme dosiahli, ako je nase riesenie splnene v porovnani s CTI modelom

### 9.2 Prínos

co sme dosiahli v praci

## 9.3 Budúce pokračovanie

navrhy na vylepsenia

# Zoznam obrázkov